



UNIVERSIDAD  
**NACIONAL**  
DE COLOMBIA

# ANALÍTICA PREDICTIVA

**CARLOS A. MADRIGAL**

PROFESOR OCASIONAL

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN Y DE LA DECISIÓN

MAESTRÍA EN INGENIERÍA - INGENIERÍA DE SISTEMAS

MAESTRÍA EN INGENIERÍA - ANALÍTICA

ESPECIALIZACIÓN EN SISTEMAS

# CONTENIDO

## **Técnicas de Validación, Regularización y Transfer Learning**

- Técnicas de validación
  - generalización, train data, test data, validation data
  - matriz de confusión, tasa de error, sensibilidad, especificidad, accuracy, precision
  - Validación cruzada, leave one out.
- Regularización
  - Bias, variance
  - L1, L2, Dropout
- Transfer Learning
- Implementación

# **TÉCNICAS DE VALIDACIÓN Y REGULARIZACIÓN**



# TÉCNICAS DE VALIDACIÓN

La validación permite conocer cómo se comporta un clasificador ante el ingreso de ejemplos nuevos, con el fin de verificar su comportamiento bajo diferentes circunstancias.

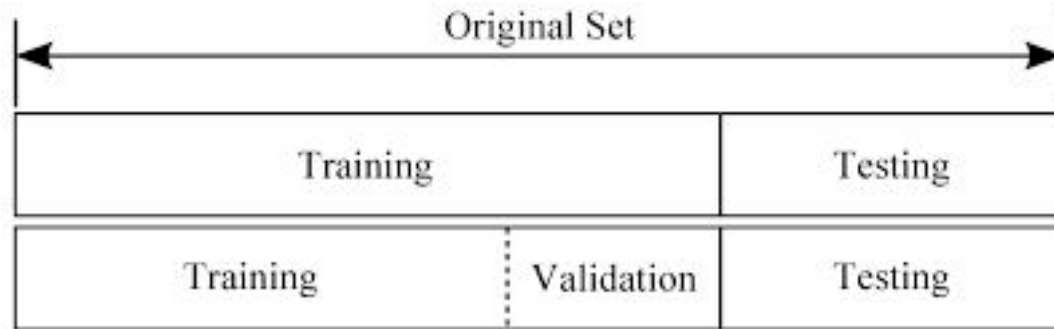
Debido a que es imposible entrenar el clasificador con todas las posibles situaciones, se corre el riesgo de un aprendizaje erróneo donde no sea capaz de **generalizar**.

Causas:

- Conjunto de entrenamiento escaso o no representativo.
- Arquitectura de la red inadecuada



# CONJUNTOS DE DATOS



**Train Data:** Conjunto de ejemplos usados para el entrenamiento.

**Validation Data:** Conjunto de ejemplos usados para seleccionar la mejor arquitectura entre varias o para escoger los mejores hiperparámetros de una arquitectura.

**Test Data:** Conjunto de ejemplos para medir el desempeño.

# CRITERIOS DE EVALUACIÓN DE CLASIFICADORES

- *Matriz de confusión*: muestra la distribución de los errores cometidos por un clasificador a lo largo de las distintas categorías del problema.

		Clase verdadera		
		0 (+)	1 (-)	
Clase predicha	0 (+)	a	b	p0
	1 (-)	c	d	p1
		$\pi_0$	$\pi_1$	N

		Predicted class		
		Cat	Dog	Rabbit
Actual class	Cat	5	3	0
	Dog	2	3	1
	Rabbit	0	2	11

- *Tasa de error*:  $(b+c) / N$
- *Sensibilidad*:  $a/(a+c)$  proporción de verdaderos positivos, también conocido como recall o rata de verdaderos positivos TP.
- *Especificidad*:  $d/(b+d)$  proporción de verdaderos negativos o rata de verdaderos negativos TN

# CRITERIOS DE EVALUACIÓN DE CLASIFICADORES

- *Accuracy (AC)*: Es la proporción de predicciones que fueron correctas con respecto al total.

$$AC = (a + d) / (a + b + c + d)$$

- *False positive rate (FP)*: Es la proporción de casos negativos que fueron incorrectamente clasificados como positivos.

$$FP = b / (b + d)$$

- *False negative rate (FN)*: Es la proporción de casos positivos que fueron incorrectamente clasificados como negativos.

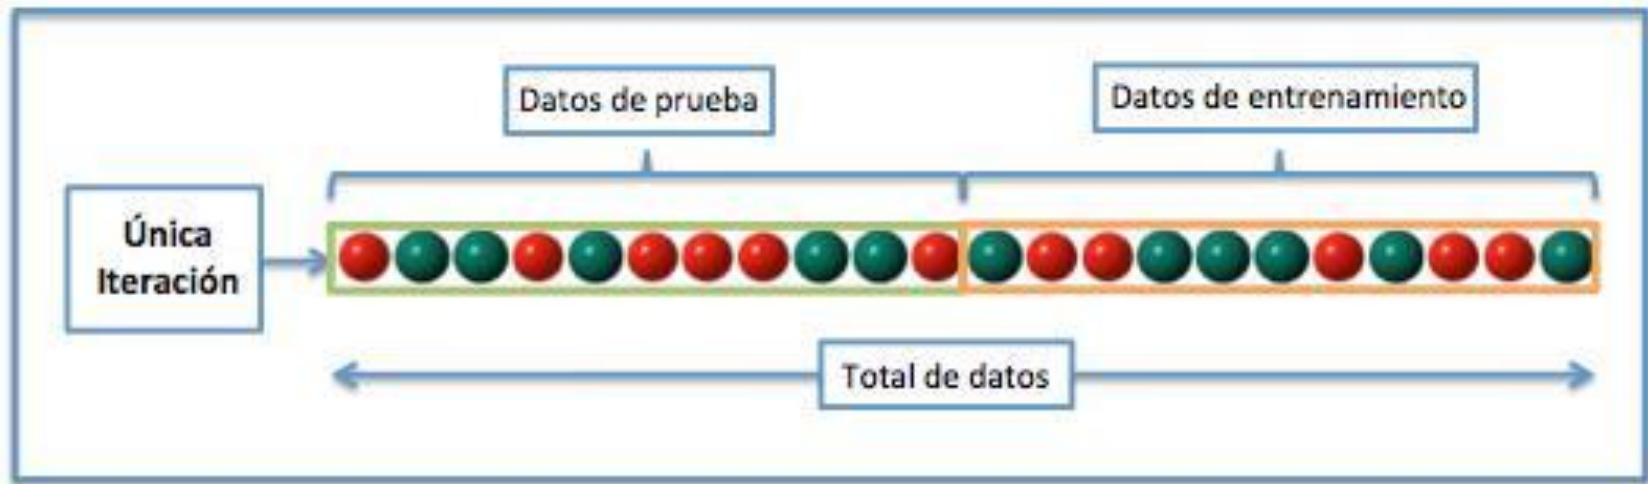
$$FN = c / (a + c)$$

- *Precision (P)*: Es la proporción de los casos positivos predichos que fueron correctos.

$$P = a / (a + b)$$

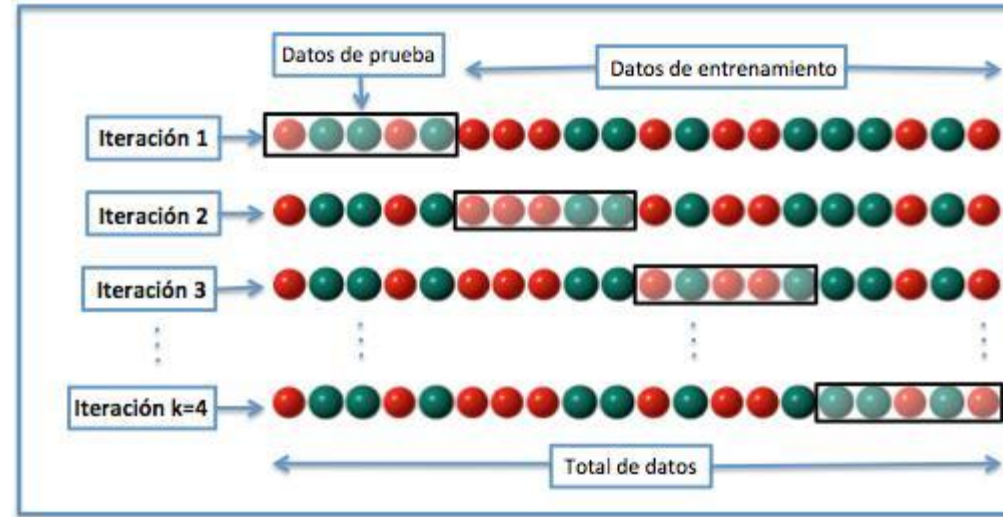
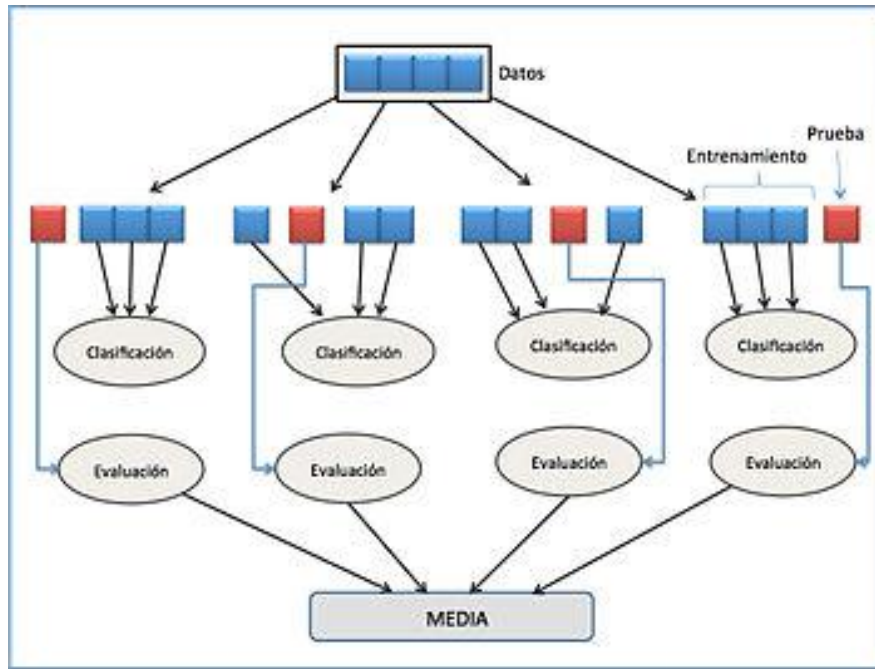


# HOLDOUT



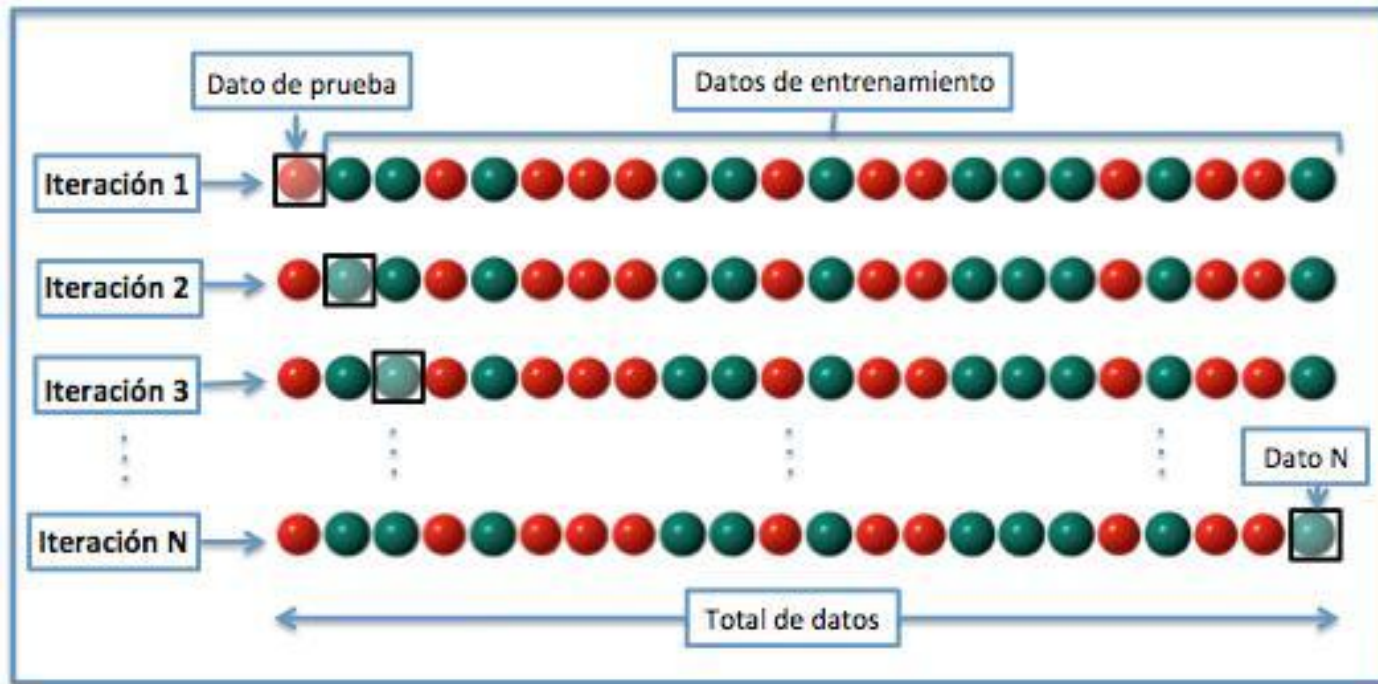
Se divide el conjunto de casos en dos grupos: conjunto de entrenamiento ( $2/3$ ) y conjunto de test ( $1/3$ ). El conjunto de entrenamiento se usa para generar el clasificador y el de test para evaluarlo.

# VALIDACIÓN CRUZADA



**Validación cruzada (cross-validation):** Se divide el conjunto de casos en K subconjuntos del mismo tamaño. Se utilizan K-1 subconjuntos como datos de entrenamiento y 1 subconjunto como datos de test. Se repite para los K subconjuntos y se calcula la media de la evaluación. Suele utilizarse K=10.


# LEAVE ONE OUT



**Dejar uno fuera (leave one out):** validación cruzada con K igual al número de casos.

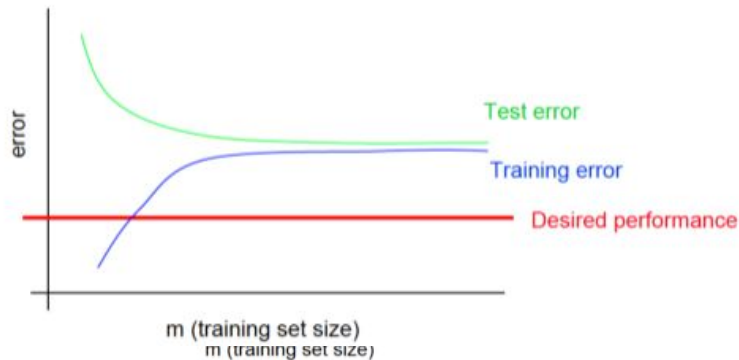
# REGULARIZACIÓN

Son un conjunto de técnicas que ayudan a que los modelos de aprendizaje puedan converger con capacidades de generalización.

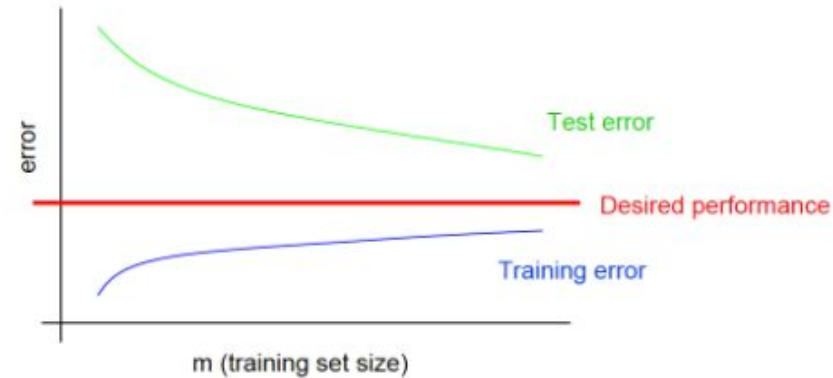


# REGULARIZACIÓN

Typical learning curve for high bias:



Typical learning curve for high variance:



**Bias:** Es la diferencia entre la medida del desempeño de la predicción con respecto al valor correcto. Un alto bias puede ser corregido a través de una arquitectura más grande o entrenando por más iteraciones.

**Variance:** Es la variabilidad entre el desempeño con los datos de entrenamiento y los datos de test. Un alto variance puede ser corregido con un conjunto de datos más extenso y/o aplicando técnicas de regularización.

# REGULARIZACIÓN

*Median Squared Error*

$$\mathcal{L}(S, Y) = e(n) = \frac{1}{2} (S - Y)^2$$

*Cross Entropy Error*

$$\mathcal{L}(S, Y) = e(n) = -(S \log Y + (1 - S) \log(1 - Y))$$

**Regularización L2**


$$\mathcal{L}'(S, Y) = \mathcal{L} + \beta \frac{1}{2} \|w\|_2^2$$

**Regularización L1**

$$\mathcal{L}'(S, Y) = \mathcal{L} + \beta \frac{1}{2} |w|$$

# DROPOUT

Es una técnica para generar la regularización de una red. Se basa en la desactivación de algunas neuronas de la red ya que pueden estar saturadas y no son útiles en el proceso de aprendizaje. Dropout solo se aplica en el proceso de entrenamiento.

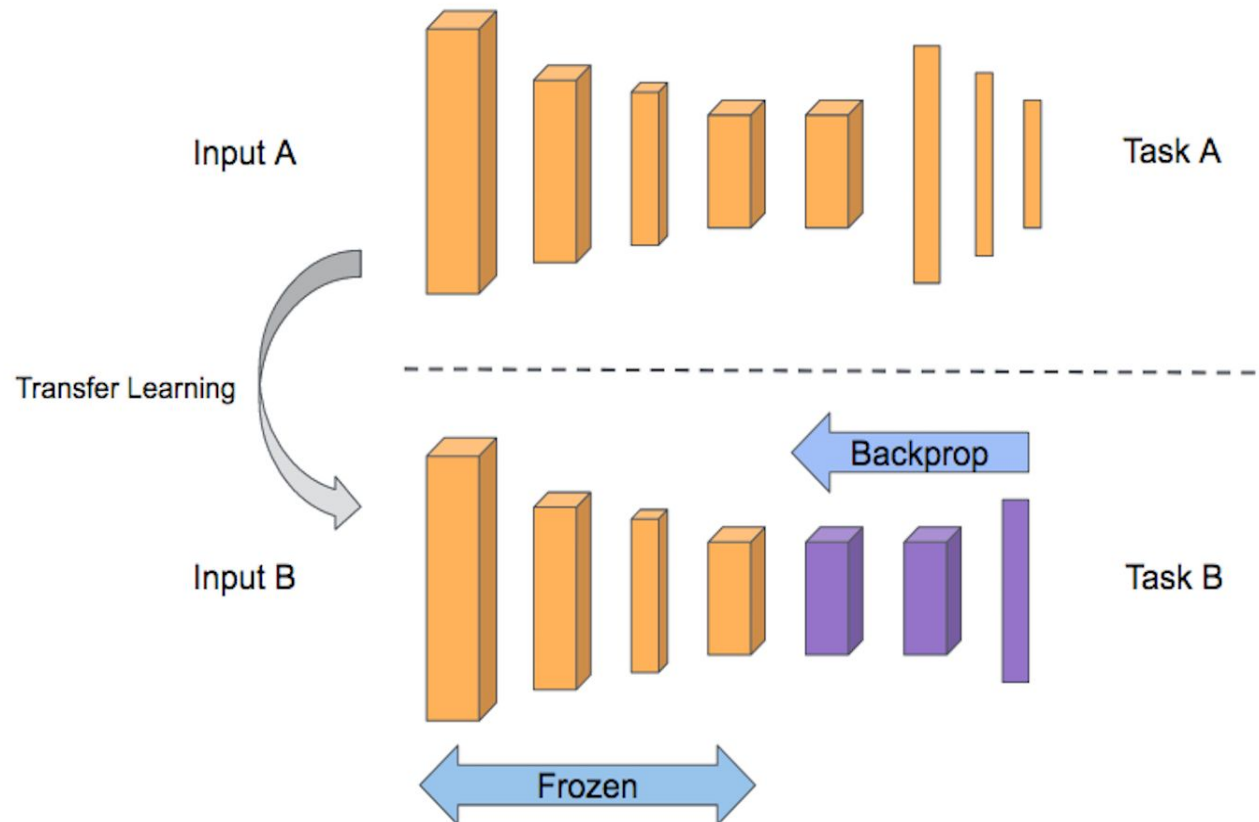


# **TÉCNICAS DE VALIDACIÓN Y REGULARIZACIÓN**



# TRANSFER LEARNING

El transfer learning es una herramienta sumamente útil para desarrollar aplicaciones de Deep Learning aun cuando no se tienen suficientes datos.



Tomada de:  
<https://medium.com/@subodh.malgonde/transfer-learning-using-tensorflow-52a4f6bcd3e>

# TRANSFER LEARNING

Para hacer transfer learning se requiere lo siguiente:

- Una arquitectura entrenada con el tipo de dato que vamos a usar
- Definir cuáles capas se van a usar y cuales a entrenar
- Inicializar los pesos de las capas elegidas con la arquitectura entrenada

Se puede hacer transfer learning de dos maneras.

- Se pueden congelar los pesos pre-entrenados y entrenar el resto,
- Se pueden actualizar también los pesos ya entrenados

# TRANSFER LEARNING

Para la arquitectura entrenada podemos acudir a la librería TensorNets en la que se encuentran varias redes, en su mayoría convolucionales.

- Se carga la red mediante el comando `modelo=nets.arquitectura`
- Se cargan los pesos preentrenados con `model.pretrained()`
- Se procesan datos en la arquitectura con el comando `model.preprocess(batch_x)`
- Y se extraen respuestas de las capas intermedias con `model.get_middles()`

# Preguntas

